¿Cómo se extienden a Marte las features de DINOv3 preentrenado con imágenes web?

Apariencia, adaptación y errores en AI4Mars

Avance del proyecto de Deep Learning · noviembre de 2026

Un modelo de fotos web, un planeta distinto

DINOv3 se preentrena con imágenes de la web; el rover Curiosity ve imágenes en escala de grises de suelo rojizo, con poca textura y mala iluminación.

El rover debe distinguir suelo, roca madre, arena y roca grande para planificar una ruta segura, y las etiquetas de expertos son pocas y ambiguas.

15,564

imágenes de entrenamiento

322

imágenes de test por conjunto (M1, M2, M3)

4

clases: soil, bedrock, sand, big_rock

4.6 k

parámetros entrenables de la sonda

Una pregunta, tres ángulos, tres hipótesis

P1 · Datos

¿La brecha es de apariencia?

Cambiamos solo cómo se ven las fotos y miramos si la sonda mejora.

H1: no es fotométrica.

P2 · Modelo

¿Dónde conviene adaptar?

Mismo presupuesto de LoRA en bloques tempranos, medios o tardíos.

H2: los tardíos ayudan más.

P3 · Errores

¿Dónde falla y lo sabe?

Acuerdo entre expertos y calibración de la confianza.

H3: el techo lo ponen las etiquetas.

Cómo lo medimos

Backbone

DINOv3 ViT-B/16 congelado; sonda lineal de 4.6 k parámetros (una por capa) como referencia de «sin adaptación»; decoder de 3.5 M y ajuste fino de los últimos bloques como cabezas más pesadas

Un factor por experimento

P1 cambia la imagen; P2 cambia dónde va LoRA (rango 8, 221 k parámetros); P3 cambia cómo se divide el test

Línea base

DeepLabV3-R50 de punta a punta, mismo split y presupuesto (3 épocas), con y sin ImageNet

Estadística

Bootstrap pareado por bloques de 10 imágenes, IC 95 %. «Real»: IC excluye 0 y $|\Delta| \geq 0.01$. «Equivalente»: IC dentro de ±0.01

Fase A: abrir el modelo

85.7 M
parámetros del ViT-B/16

215
GFLOPs por imagen de 512 px

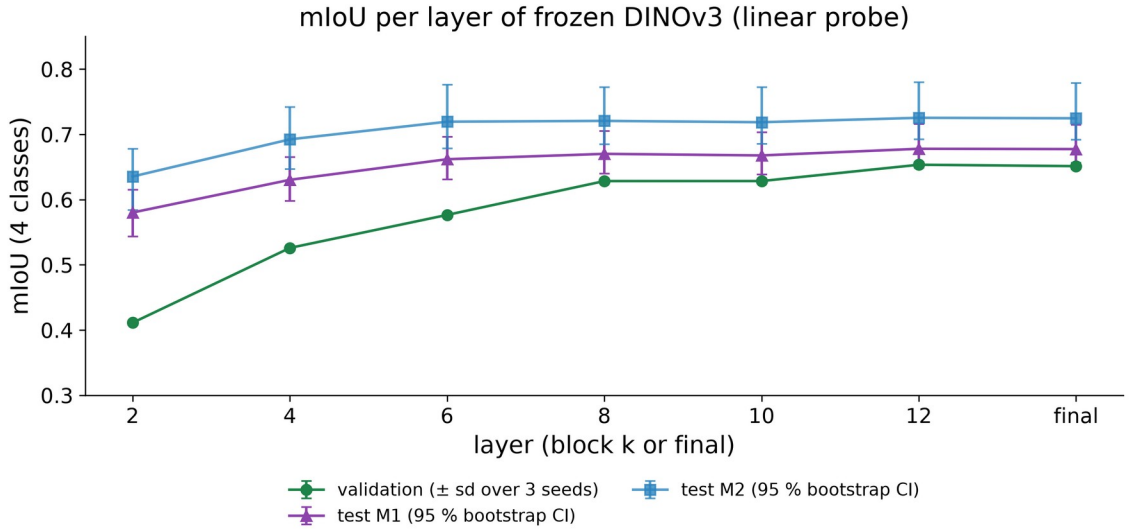
12 × 7.1 M
bloques idénticos de 17.8 GFLOPs

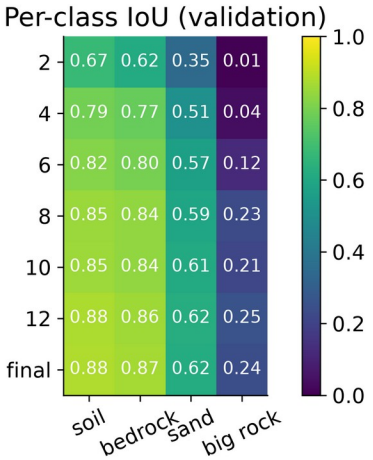
Los 12 bloques cuestan lo mismo, así que adaptar los primeros o los últimos es una decisión sobre dónde, no sobre precio.

También medimos latencia, memoria pico y estadísticas de las features por bloque.

Pendiente: mapa del campo receptivo y visualización de features intermedias.

Capas: hasta dónde llegan las features





- Sonda en la última capa: 0.677 / 0.725 (M1 / M2). El bloque 6 ya da el 98 % del valor final.
- Ninguna capa intermedia supera a la última (mejor en validación, bloque 10: −0.010, IC [−0.021, +0.001]).

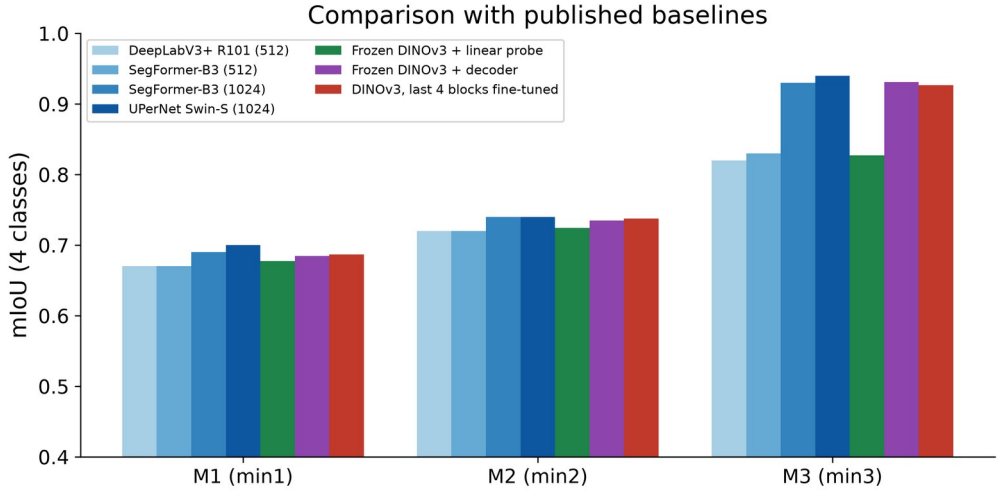
Cabezas más pesadas y preentrenamiento

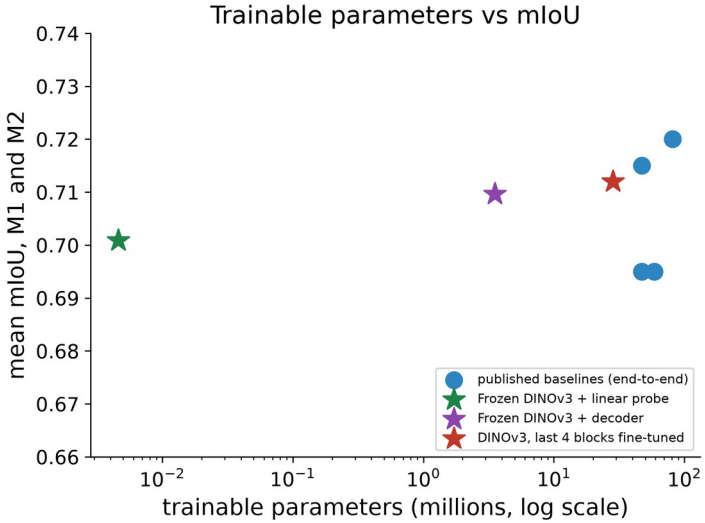
Configuración	Params	M1	M2
Sonda, última capa	4.6 k	0.677	0.725
Decoder (bloques 3, 6, 9, 12)	3.5 M	0.684	0.735
Últimos 4 bloques ajustados	28 M	0.687	0.737
DINOv2 B/14, sonda	4.6 k	0.664	0.714
ViT aleatorio, sonda	4.6 k	0.264	0.272

Tres semillas; DINOv2 y ViT aleatorio con 2,000 imágenes de entrenamiento.

- Sonda, decoder y ajuste fino quedan a menos de 0.012 mIoU.
- El ViT con pesos aleatorios llega a 0.264: el preentrenamiento importa.
- DINOv3 supera a DINOv2 en +0.013 en M1 y la diferencia no se explica por el tamaño de la grilla de tokens.
- Con 250 imágenes etiquetadas la sonda ya da el 99 % de su mIoU.

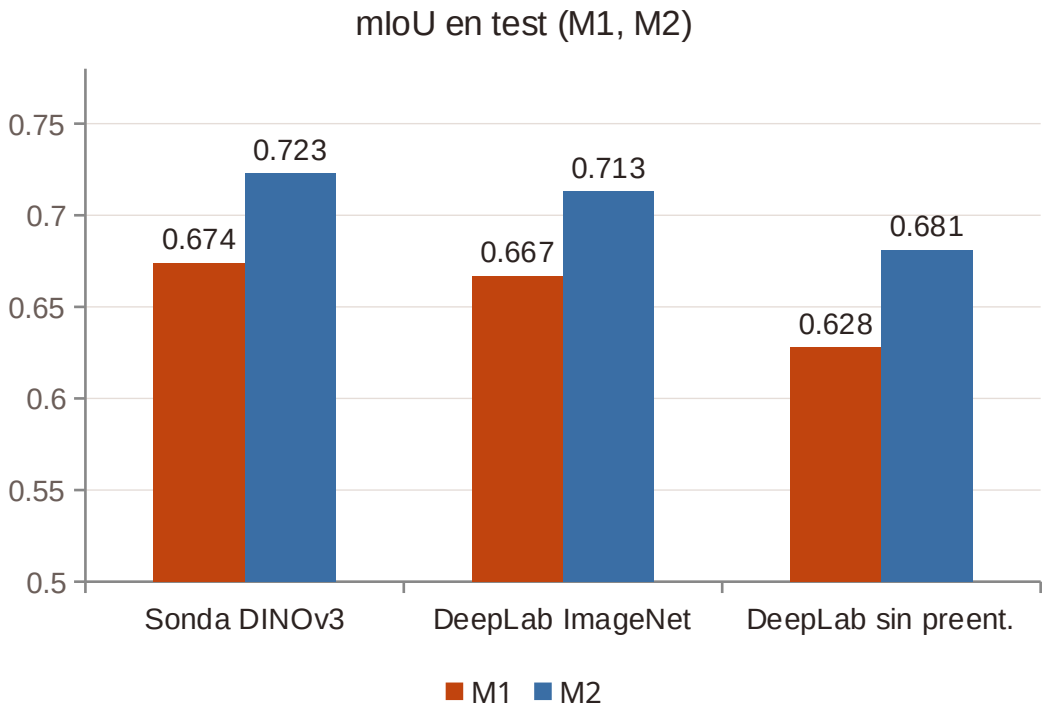
Frente a los modelos publicados





- La sonda queda a unos 0.02 del mejor modelo publicado (UPerNet Swin-S a 1,024 px, 0.70 en M1) con 4.6 k parámetros en vez de 47–81 M.
- Comparación indicativa: las cifras publicadas son una corrida, con otro split y su propia convención de mIoU.

La sonda iguala al modelo de punta a punta

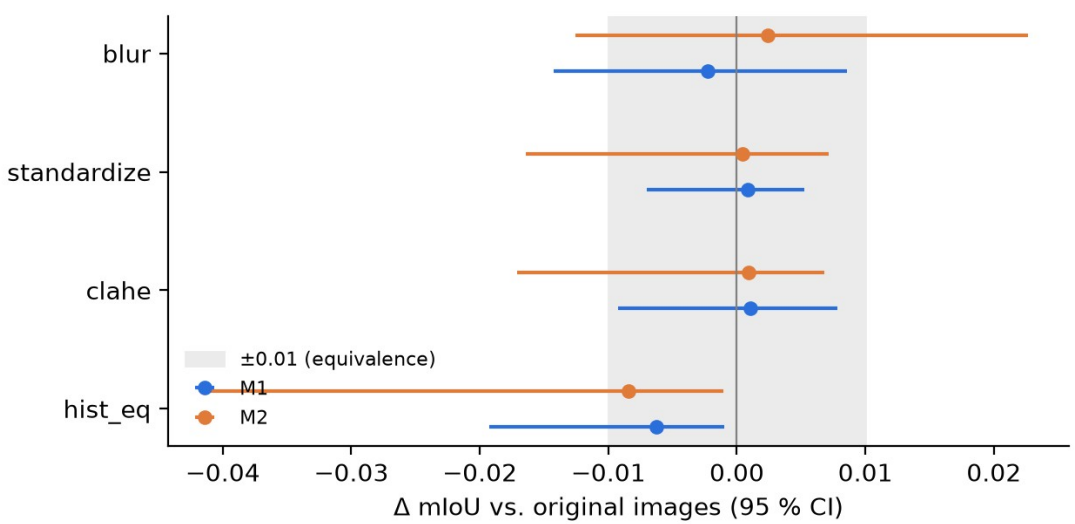


8,600×

menos parámetros entrenables (4.6 k frente a 39.6 M), con diferencia no distinguible (M1: −0.007, IC [−0.025, +0.008])

Sin preentrenamiento el baseline queda claramente atrás (−0.046): el preentrenamiento importa.

P1: la brecha no es de apariencia



- CLAHE y estandarización son equivalentes a las imágenes originales en M1 (+0.001).
- La ecualización global baja algo (−0.006) y el desenfoque no hace daño (−0.002).
- Ninguna transformación mejora. La clase que más cae con desenfoque es soil, no sand como predijimos.
- En M2 los intervalos son más anchos que ±0.01: no se puede cerrar.

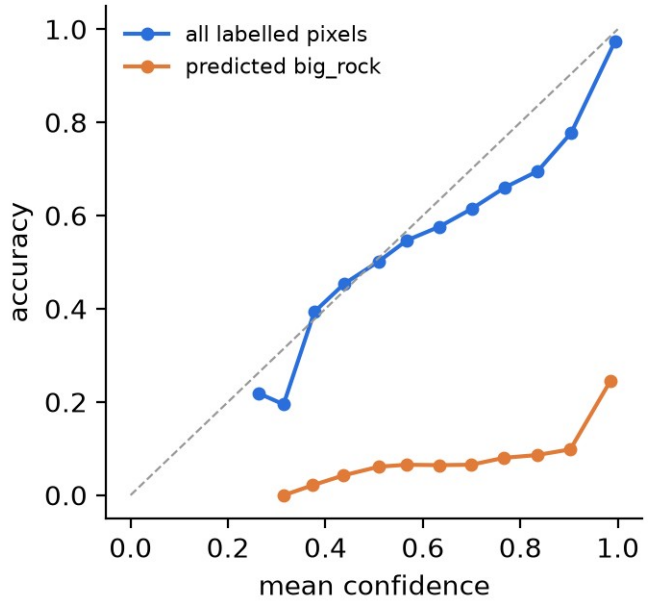
P2: adaptar casi no aporta, vaya donde vaya

Configuración	Params	M1	M2
Sonda (control)	4.6 k	0.674	0.723
LoRA early (bloques 1–2)	221 k	0.681	0.730
LoRA mid (bloques 6–7)	221 k	0.679	0.728
LoRA late (bloques 11–12)	221 k	0.681	0.731

LoRA rango 8, 2 semillas, 2 épocas por corrida.

- Todas las zonas ganan +0.005 a +0.007 sobre la sonda, bajo nuestro umbral de 0.01.
- Las zonas no difieren entre sí (late − early en M1: −0.000, IC [−0.006, +0.015]).
- **En validación sí se separan (mid y late 0.69–0.72; early 0.62–0.64). No lo explicamos.**

P3: el techo está en las etiquetas y en big_rock



0.86 → 0.55

mIoU donde coinciden 3 expertos frente a donde etiquetó 1 (0.862 y 0.546; +0.315)

ECE 0.029

calibración global buena

+0.674

confianza menos acierto en píxeles predichos big_rock

45 %

de los píxeles de big_rock no se detectan

Hipótesis y veredictos

H1	**La brecha no es fotométrica** Ninguna transformación mejora; M2 no permite cerrar	**Inconclusa**
H2	**Los bloques tardíos ayudan más** late − early ≈ 0; validación y test discrepan	**Inconclusa**
H3	**El techo lo ponen las etiquetas y big_rock** +0.315 por acuerdo; sobreconfianza +0.674	**Apoyada**

«Inconclusa» significa que los datos no confirman ni descartan el efecto con 322 imágenes de test, no que el efecto sea cero.

Limitaciones, sesgo y ética

Experimentos

LoRA: 2 semillas y 2 épocas.

Baseline: 1 semilla, 3 épocas; sin preentrenar seguía mejorando.

Early stopping cortó las sondas de P1 en la época 5.

Validación y test discrepan en las zonas de LoRA.

Teardown sin campo receptivo ni visualizaciones.

Datos, sesgo y ética

Un backbone, un rover, 322 imágenes de test.

Etiquetas de entrenamiento de crowdsourcing y ruidosas.

big_rock aparece en solo 5 imágenes de M3.

Datos públicos de NASA sin información personal.

Estos modelos no deben usarse solos para detectar peligros.

Qué sigue

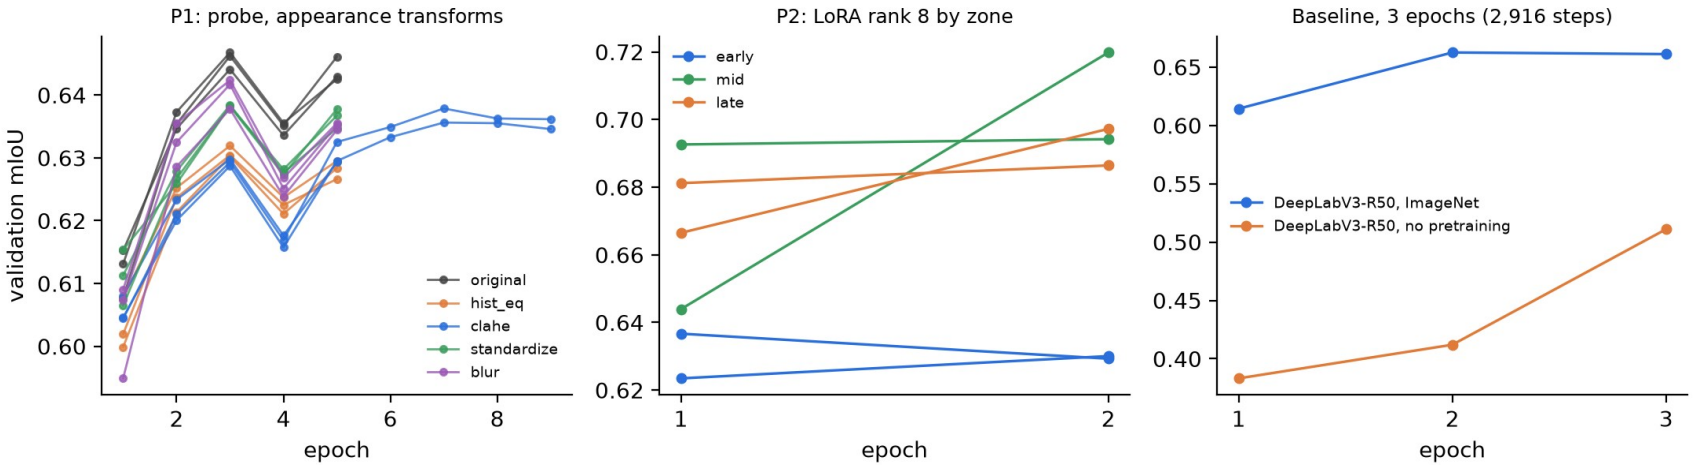
Siguiente (propuesto)	LoRA a 6 épocas en las tres zonas y baselines a 10 épocas, en Kaggle (unas 15 h de GPU, ~8 h de reloj con 2 sesiones). Aclarar la discrepancia validación/test.
Antes del 16/11	Campo receptivo y visualización de features; revisar el cuaderno de decisiones; entrega de trabajo.
18–20/11	Presentación y defensa en WAIMLAp, con el póster actualizado a este estudio.
30/11	Artículo final de 4–8 páginas con la retroalimentación del taller.

Las features de DINOv3 ya funcionan en Marte con casi ninguna adaptación

- La brecha no es de apariencia.
- Adaptar bloques tempranos, medios o tardíos aporta ~0.006 mIoU.
- El techo está en las etiquetas y en big_rock, donde el modelo está seguro y se equivoca.

Código, resultados y logs: github.com/gonzaquis29/DinoV3-AI4Mars

Anexo: curvas de validación por época



Solo se registró el mIoU de validación por época; no hay pérdida de entrenamiento. Las sondas alcanzan su máximo hacia la época 3; el baseline con ImageNet se estanca cerca de 0.66.